Pacte
Laboratoire de sciences sociales

Panelvico

Journée Annuelle So-Mate
Le coût caché de l'open science

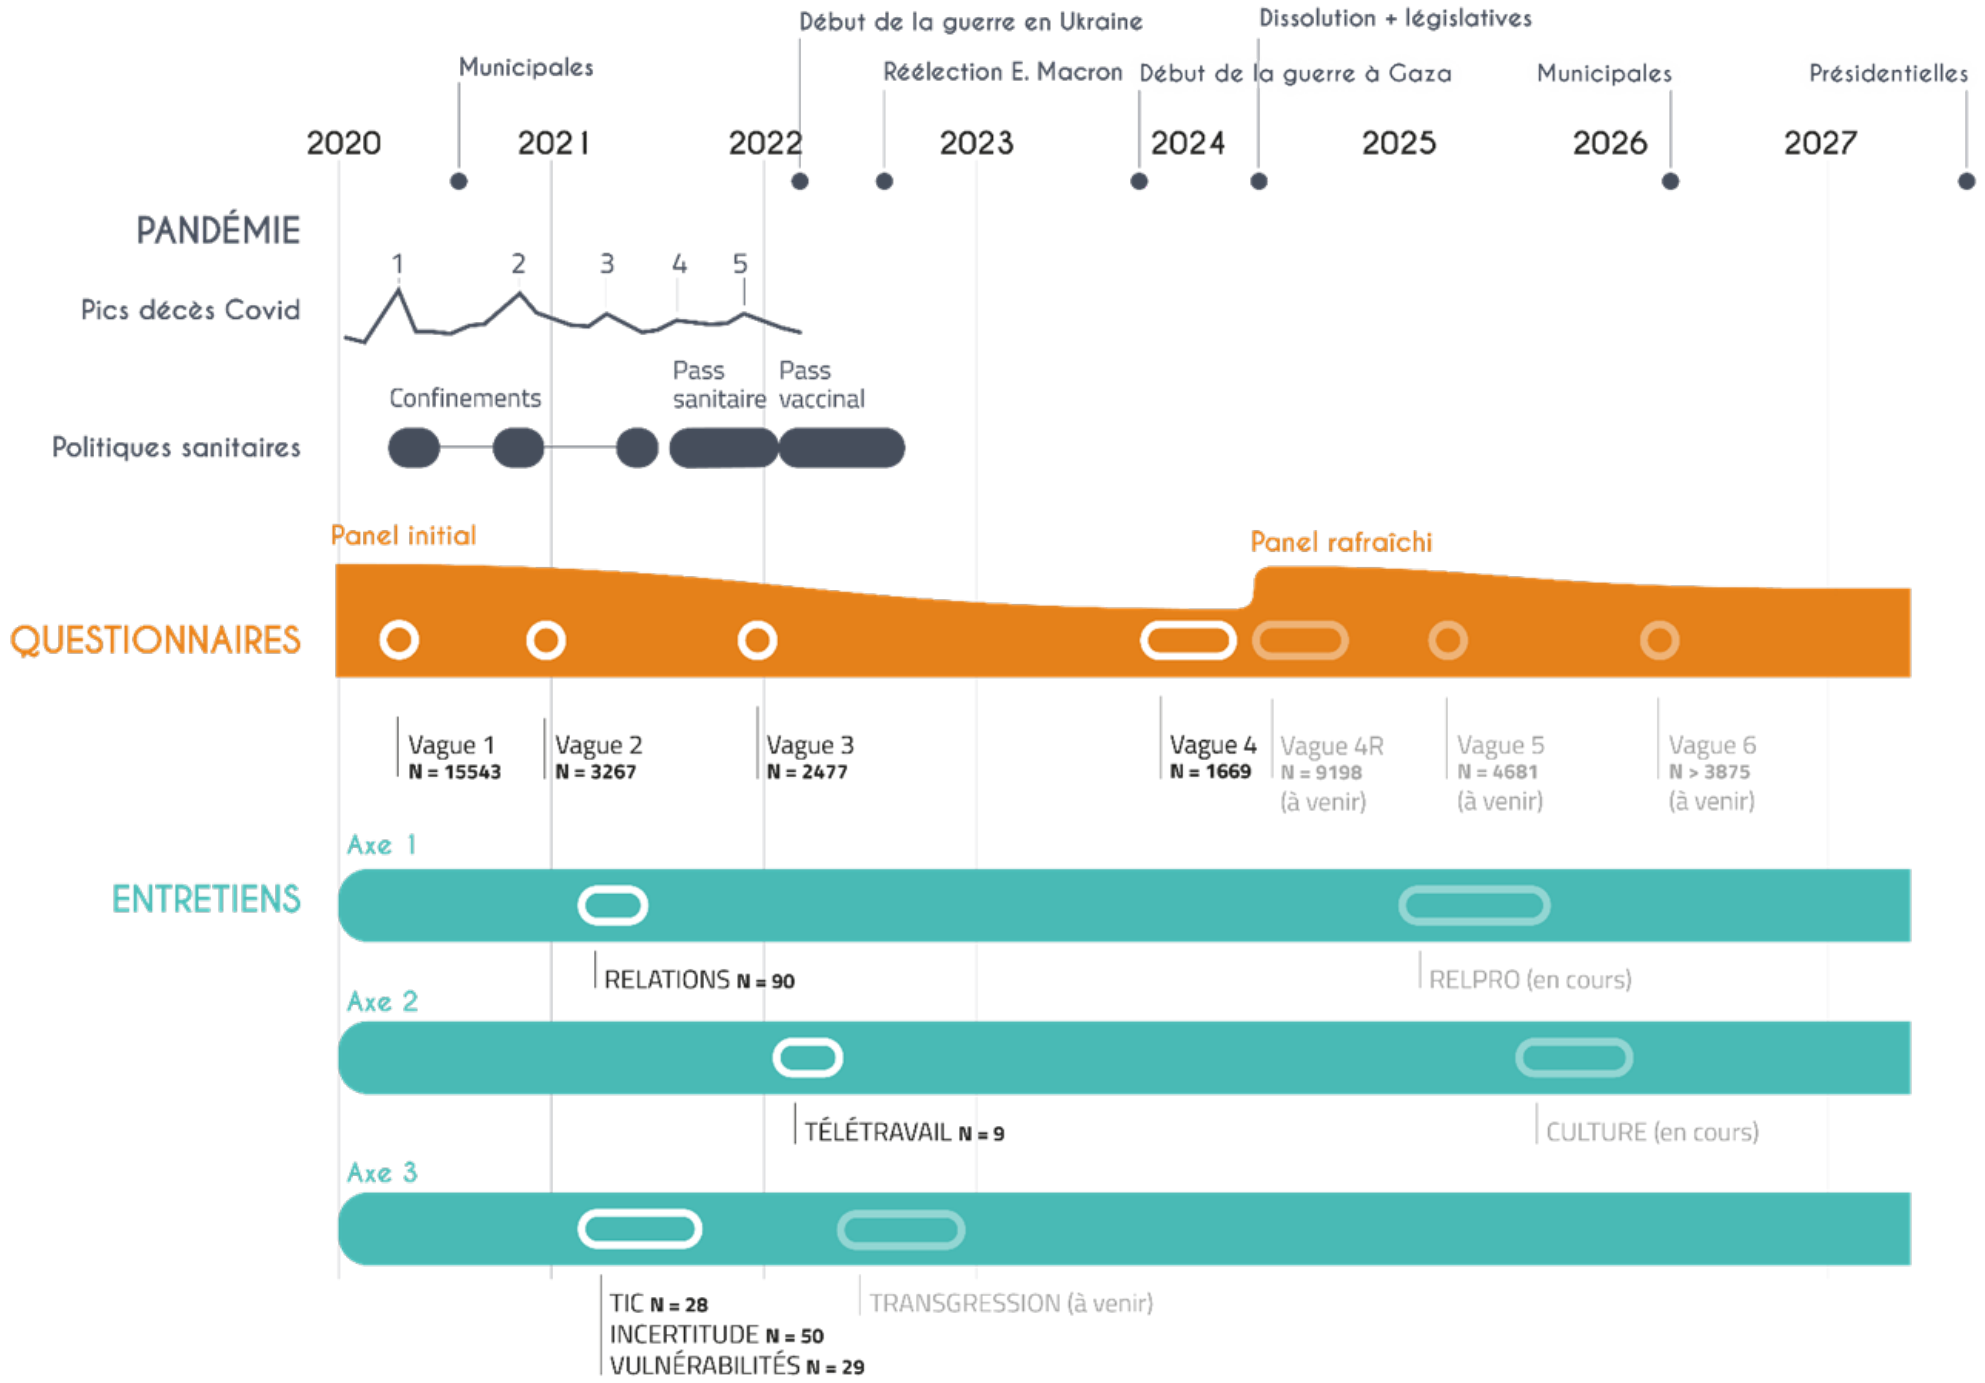
Ouvrir les données en sciences sociales, à quel prix ?

Retours d'expérience de la mise à disposition de l'enquête Vico auprès du CDSP

Laurine Thizy – laurine.thizy@gmail.com
Chargée de recherches post-doctorales FNRS – Pragmapolis
Chercheuse associée à l'ANR Panelvico
5 novembre 2026

Présentation du programme de recherche Panelvico

- **Deux programmes ANR** successifs : Vico (2020 - 2022) et Panelvico (2023 - 2027) réunissant trois laboratoires (Pacte à Grenoble, MISST à Toulouse, LEST à Aix-Marseille) et plus de 40 chercheureuses : https://vico.hypotheses.org/
- **Enquête longitudinale en méthodes mixtes** pour documenter l'ampleur des changements causés par la crise sanitaire de Covid 19 sur le lien social, le rapport au travail, au logement, à l'Etat et aux usages du temps libre
- **Panel** de plusieurs milliers de personnes, recruté au moment du premier confinement du printemps 2020, rafraîchi à l'automne 2024
  - 6 vagues de questionnaires en ligne auto-administrés
  - 9 vagues d'entretiens, dont 5 à ce jour sont en cours de mise à disposition


Début de la guerre en Ukraine
Dissolution + législatives
Municipales
Réélection E. Macron
Début de la guerre à Gaza
Municipales
Présidentielles
2020
2021
2022
2023
2024
2025
2026
2027
PANDÉMIE
Pics décès Covid
1
2
3
4
5
Confinements
Pass sanitaire
Pass vaccinal
Politiques sanitaires
Panel initial
Panel rafraîchi
QUESTIONNAIRES
Vague 1 N = 15543
Vague 2 N = 3267
Vague 3 N = 2477
Vague 4 N = 1669
Vague 4R N = 9198 (à venir)
Vague 5 N = 4681 (à venir)
Vague 6 N > 3875 (à venir)
Axe 1
ENTRETIENS
RELATIONS N = 90
RELPRO (en cours)
Axe 2
TÉLÉTRAVAIL N = 9
CULTURE (en cours)
Axe 3
TIC N = 28
INCERTITUDE N = 50
VULNÉRABILITÉS N = 29
TRANSGRESSION (à venir)

Une politique d'ouverture rapide des données produites

- Une **mise à disposition des données** prévue dès le projet ANR
- Un **dépôt en méthodes mixte**s, sous forme de collection articulant les données quantitatives (questionnaires en ligne) et qualitatives (entretiens) et pouvant être augmenté au fur et à mesure : https://data.sciencespo.fr/dataverse/vico
- Accompagné d'un **datapaper** publié en octobre 2026 au DEMC (N°4 / 2026) : « Les conditions de vie et les relations sociales pendant et après la crise sanitaire du Covid-19. Présentation des données de l'enquête Vico », Laurine THIZY, Pierre MERCKLÉ, Claire BIDART, Michel GROSSETTI, Antoine MACHUT, Equipe VICO https://demc-journal.org/articles/revue-4/3556-les-conditions-de-vie-et-les-relations-sociales-pendant-et-apres-la-crise-sanitaire-du-covid-19

Objectifs de la présentation

- Un retour réflexif sur le travail de mise à disposition de ce corpus en **méthodes mixtes, avec une focalisation sur les coûts, souvent cachés, d'une telle entreprise**
- En partie appuyé sur un article co-écrit avec Pierre Mercklé, à paraître dans la Rubrique «Théories et méthodes » de **Sociologie** : « Ouvrir les données en sciences sociales, à quel prix ? Éléments de réflexion à partir d'une enquête longitudinale collective en méthodes mixtes »
- Explorer les différents coûts et sur qui ils reposent, l'enjeu étant : y a-t-il un intérêt scientifique au réusage qui serait supérieur à la réalisation de nouvelles enquêtes ?

Plan

I. Ce que coûte la mise à disposition d'un corpus aux équipes de recherche
- 1.1 Des coûts de formation
- 1.2 Des coûts de coordination
- 1.3 Des coûts de préparation du corpus

II. Ce que coûte la mise à disposition d'un corpus aux données elles-mêmes : la pseudonymisation comme dégradation de la qualité des données
- 2.1 Sélectionner et documenter les données mises à disposition
- 2.2 Anonymiser des données quantitatives
- 2.3 Pseudonymiser des données qualitatives

III. Ce que coûte la mise à disposition d'un corpus aux enquêté-es : estimer et limiter les risques de réidentification
- 3.1 Quel consentement des enquêté-es à l'ouverture des données ?
- 3.2 La difficile évaluation du risque de réidentification
- 3.3 Ce que coûte un-e enquêté-e qui se retourne contre l'enquête

IV. Ce que coûte le réusage aux futur-es chercheur-ses
- 4.1 Avantages
- 4.2 Inconvénients et limites
- 4.3 Objectiver les réusages

Je laisse de côté le détail de notre protocole d'anonymisation/pseudonymisation ainsi que la présentation du cadre juridique de la science ouverte et de la protection des données, mais on pourra y revenir en discussion…

I. Ce que coûte la mise à disposition d'un corpus aux équipes de recherche

Préambule : une rapide estimation du coût de la mise à disposition des données Vico

- En tout, **au sein du projet ANR Vico**, une quantité de travail estimée à
  - 22 mois de stages ETP (6 stagiaires)
  - 30 mois ETP de post-doctorat
  - 10 mois ETP de chercheur/ingénieurs titulaire
  - mobilisation des équipes de soutien à la recherche de trois laboratoires, de trois PUD, de la DPD du CNRS, du CDSP

⇒ environ 150 000€ sur les 850 000 du projet

- A quoi il faut encore ajouter la **masse salariale** des institutions publiques partenaires et le financement des structures et des outils de travail

⇒ Au moins doubler ce prix

Et ce coût doit être pensé comme un **coût d'opportunité** : toutes les ressources investies dans la mise à disposition sont des ressources qui ne sont pas investies dans l'analyse et la valorisation des résultats et la production de nouvelles enquêtes !

1.1 Des coûts de formation

Connaître (et s'approprier !) :

- le **cadre juridique** de la science ouverte et de la protection des données: RGPD, loi Valter-Lemaire, dilemme "aussi ouvert que possible, aussi fermé que nécessaire", différences entre données sensibles/données personnelles, continuum **anonymisation/pseudonymisation**
- les **techniques et outils** d'anonymisation quanti (sdcMicro dans R) et quali (en tâtonnant, mais le nouveau Sonal Pi est une belle promesse)
- les **banques de dépôt** possibles et leurs exigences / leur responsabilité
- Les différents **acteurices académiques** qui peuvent servir de ressource : DPD, IR et IE, collègues spécialistes…

➔ Une formation souvent sur le tas, y compris dans un environnement institutionnel très favorable comme l'ANR Panelvico

1.2 Des coûts de coordination

- De nombreux échanges collectifs pour **définir un protocole d'anonymisation** et **choisir les données à ouvrir**, en concertation avec
  - le groupe de travail dédié à la gestion des données, incluant plusieurs ingénieur·es de recherche bien formé·es **(Cavallo & Noûs, 2019)**
  - le comité de pilotage
  - le délégué à la protection des données du CNRS
  - l'organisme déposant, le CDSP
- Des **coûts de coordination** et de validation successives, nécessaires à un fonctionnement démocratique mais qui créent des ralentissements structurels du travail
- Des pratiques de travail / des rapports aux données et à leur protection qui peuvent différer et révéler des **enjeux émotionnels** liés à l'attachement aux données produites avec des conséquences très concrètes sur le travail (absence de réponse à des mails, ralentissement "passif"…)

1.3 Des coûts de préparation du corpus

- Sur qui repose le travail ?
  - Des **responsables de projet** déjà saturé-es de travail administratif et de direction de projet
  - Des **ingénieur-ses d'étude ou de recherche** : Ex. Une série de tâtonnements successifs et d'essais d'outils avec Valentin Brunel et Max Béligné (identification des entités nommées, anonymisation semi-automatique…)
  - Des **« petites mains » précaires** de l'ESR sur ou sous-diplômées : un **problème de turn-over** de la main d'oeuvre
  - Des **gestionnaires et des RH** au bord du burn-out qui tardent à éditer des contrats courts Ex: un renouvellement de contrat rendu absurdement impossible
- Un décalage entre la **temporalité longue de la mise à disposition** et la **temporalité courte des projets et CDD** = perte de temps, de compétences, formations des stagiaires à recommencer entièrement…

II. Ce que coûte la mise à disposition d'un corpus aux données elles-mêmes

La pseudonymisation comme dégradation de la qualité des données

2.1 Sélectionner et documenter les données mises à disposition

- **Qu'est-ce qu'une « donnée » ?** Définir ce qu'est « l'ouverture des données » suppose de définir préalablement ce que sont les données (Stérin & Noûs, 2019) et en quoi consiste leur ouverture (Courmont, 2017) ➔ faut-il partager nos scripts R ? Nos résumés d'entretiens ? = arbitrage entre « ce qui doit être diffusé et ce qui relève de [la] création scientifique » (Beauchemin *et al.*, 2019).
- **Sur qui repose la « souveraineté des données » ?** Une question qui commence bien avant la mise à disposition, avec l'enjeu de ne pas invisibiliser le travail des dominé-es… ➔ Ex : embargo d'un an sur les entretiens
- **Comment documenter un corpus ?** Arborescence lisible et logique, readme, notices explicatives… ➔ longs recodages pour produire des métadonnées standardisées

! La standardisation est d'autant plus fastidieuse que l'équipe de recherche est grande, les protocoles d'enquête peu définis et les données qualitatives…

Processus	Pseudonymisation	Anonymisation
Statut des données	Données personnelles (indirectement identifiables, elles sont donc soumises au RGPD et à la loi Informatique et Libertés).	Anonymes
Réutilisation des données	Sous conditions	Sans restriction
utilité des données	Conservée, car le niveau de détail des données n'a pas été altéré.	Modifiée à différents niveaux selon les objectifs visés et les méthodes utilisées.
Méthodes à mettre en œuvre	Compteur, générateur de nombres aléatoires, fonction de hachage, chiffrement par clé secrète, etc.	Varie en fonction des objectifs visés : confidentialité différentielle, randomisation, k-anonymat, l-diversité, t-proximité, etc.
Complexité de la mise en œuvre	Simple à moyenne	Dépend des objectifs recherchés : cela peut être simple dans certains cas, comme l'agrégation ou le comptage, et plus complexe dans d'autres.

source : https://www.cnil.fr/fr/identifier-les-donnees-personnelles

2.2 Anonymiser des données quantitatives

- **La suppression de données** : retirer les identifiants directs (noms, adresses, numéros de sécurité sociale…), les quasi-identifiants sensibles (dates de naissance exactes, codes postaux précis), les valeurs rares et les informations inutiles donc supprimables (recommandations de la CNIL).
- **Le regroupement de modalités** (généralisation) : agglomérer des réponses en créant des catégories plus larges.
- **Les techniques de perturbation statistique** (randomisation) : créer du bruit aléatoire dans les données selon des distributions contrôlées
- **La micro-agrégation de variables** : regrouper des observations similaires en clusters, puis à remplacer des valeurs individuelles par la moyenne du groupe. Cette technique préserve les relations entre variables tout en empêchant l'identification directe.
- Le **k-anonymat** garantit quant à lui que chaque personne dans un jeu de données est indistinguable d'au moins k-1 autres personnes partageant les mêmes attributs quasi-identifiants. La valeur du *k* est fixée arbitrairement par les équipes en charge de l'anonymisation, qui définissent elles-mêmes le niveau de risque qui leur semble acceptable. S'il n'est pas atteint, il faut renforcer l'anonymisation grâce aux méthodes précédemment évoquées.
- La **L-diversité** renforce encore cette protection en exigeant qu'au sein de chaque groupe de k personnes indistinguables, il y ait au moins une valeur différente pour la ou les variables sensibles (état de santé, revenu...), afin d'éviter qu'on puisse déduire de l'information sensible même sans identification exacte de la personne.

2.2 Anonymiser des données quantitatives

Pour l'ANR Panelvico :

- pas de randomisation
- regroupement de variables :
  - l'âge en tranches quinquennales
  - le diplôme en cinq catégories
  - la catégorie socioprofessionnelle auto-déclarée en neuf catégories,
- Suppression des personnes aux propriétés sociales rares dans le corpus (ultramarin·es, autres genres que masculin ou féminin…)
- Traitement spécifique pour les **questions ouvertes**

2.3 Pseudonymiser des données qualitatives

- La **suppression**
- **L'hyperonymie** : /!\ Elle ne doit pas être réidentifiante → ce que nous avons choisi pour les **lieux**, les **entreprises**, les **problèmes de santé** (quand cela était possible), …
- La **substitution** : Ex : les prénoms **(Coulmont, 2017)** → ce que nous avons choisi pour les **prénoms**
- **L'invention** : Ex : **Boulet, 2023** ; **Perrin, 2025** → envisagée, mais abandonnée car supposait une table de correspondance qui revient à une hyperonymie
- **L'introduction de bruit** : **Zolesio, 2011** ; **Nicaise, *à paraître*…**
- **Le résumé** : synthétiser des informations trop identifiantes → ce que nous avons choisi pour **certains passages trop identifiants**

III. Ce que coûte la mise à disposition d'un corpus aux enquêté-es :

Estimer et limiter les risques de réidentification

3.1 Quel consentement des enquêté-es à l'ouverture des données ?

Consentement ou motif d'intérêt public ? différencier les enjeux réglementaires et les enjeux déontologiques

- Traitement autorisé en faisant valoir le **motif d'intérêt public** du projet ANR. Ce motif est également valable pour le dépôt en données ouvertes, étant donné que le traitement de ces données s'inscrit dans le prolongement de notre objectif initial à des fins de recherche.
- Mais, par souci éthique, en 2025, ajout de **cases de consentement spécifique** concernant l'ouverture des données, valable rétroactivement pour l'ensemble des données collectées + information spécifiques aux personnes sorties du panel
- Problème : collecter et stocker des consentements revient ni plus ni moins à conserver une t**able de correspondance** entre un numéro d'identification (dans notre cas, l'identifiant de panel) et des données personnelles directement identifiantes (nom, prénom, parfois mail ou numéro de téléphone). Or cela empêche toute anonymisation, à moins de détruire les consentements et de se trouver ainsi dans l'incapacité d'apporter la preuve de l'accord des participant·es en cas de litige juridique.

3.2 La difficile évaluation du risque de réidentification

Le risque de réidentification dépend :

- **Des modalités de diffusion et de réusages des données :** qui y a accès ? À quelles conditions ? (valable pour le partage de la main à la main et les dépôts) = des données peuvent être anonymes pour les un-es et pseudonymes pour les autres
- **Du profil des personnes susceptibles de réidentifier les enquêté·es :** un individu lamba ? un individu compétent ayant une envie de nuire ? les proches des enquêté·es ou les personnes qui connaissent bien le terrain (question centrale pour l'ethnographie) ? les enquêté·es elleux-mêmes ? **(Laurens & Neyrat, 2010 ; Lutard-Tavard, 2014).**
- Des **compétences, du temps, de la disponibilité et de la technologie au service des attaquant-es** : *l'IA change la donne*. Ex : la réidentification instantanée d'un enquêté par Claude IA après pseudonymisation attentive de son entretien…
- Des **conséquences concrètes** de la levée de l'anonymat pour les participant-es à l'enquête

3.2 La difficile évaluation du risque de réidentification

- **Ce risque est non nul** pour les données VICO :
  - l'échantillon est de grande taille mais il repose en partie sur des relations d'interconnaissance
  - certaines des données peuvent être considérées comme sensibles (données de santé, opinions politiques…)
  - les réidentifications sont facilitées par les transcriptions d'entretiens et la possibilité de les apparier avec les données quantitatives sous conditions
  - les modalités d'accès à ces données sur la plateforme du CDSP sont relativement libérales (adresse électronique universitaire et acceptation de la licence)

- Mais nous avons estimé qu'il est raisonnable et acceptable :
  - compétences techniques importantes pour réidentifier
  - malveillance peu probable
  - données diffusées étaient faiblement compromettantes pour les enquêté·es.

3.3 Ce que coûte un-e enquêté-e qui se retourne contre l'enquête

- **Quand les enquêté-es contestent les (ré)usages de leurs données…**
  - Enjeu de reconnaissance professionnelle
  - Sentiment d'humiliation ou de diffamation **Juan Torreiro et Isabelle Sommier**
  - Atteinte à la vie privée Ex : **Frédéric Chateigner 2007/2008** = portrait de son enquêtée en écrivaine ratée, a obtenu le pilonnage de l'ouvrage
  - Sentiment de trahison Ex : enquête de **Raphaël Perrin**
  - Position de principe ou impression d'être instrumentalisé pour une carrière universitaire Ex : enquête de **Sarah Nicaise**…
- **Un exemple** dans notre enquête : une enquêtée qui a demandé la suppression de ses données
  - Saisie du DPD + suppression des informations de toutes nos bases de données
  - Mais des données déjà mises à disposition… + impossible de contrôler parfaitement la dissémination du corpus

IV. Ce que coûte le réusage aux futur-es chercheur-ses

4.1 Les avantages du réusage…

Immense gain de temps lié à l'effort d'enquête épargné

- Pas de méthodologie à implémenter
- Pas de recrutement de participant-es
- Pas de temps consacré à l'enquête

4.2 Les limites et inconvénients…

- Il faut savoir que les données existent
- Il faut y avoir accès relativement facilement
- Des dispositifs d'enquête prévus pour d'autres problématiques, qui ne répondent pas forcément aux questions de recherche des nouveaux/elles chercheur-ses. Ex : l'hyperonymie empêche des réusages
- Cela suppose de comprendre ce qui a été fait par d'autres, comment, et pourquoi… sachant que tout n'est pas objectivable, y compris avec les meilleurs datapapers possibles = la **« part non transcrite du réel »** (Bizeul, 2021, p. 9),

4.3 Objectiver les réusages

- Difficile… pour des raisons de confidentialité et de traçabilité des réusages !
- Ex : première vague de l'enquête Vico, déposée auprès de Quêtelet Progedo Diffusion en 2021 : enquête « commandée » trois fois, en 2024, par trois étudiant·es en Master de sciences politiques, de sociologie et d'économie de Lille et de Paris-Nord, pour des analyses destinées à leur mémoire de recherche.
- réutilisation de l'ensemble des 1 600 enquêtes de Progedo cette année-là : total de 1 363 demandes (soit environ 0,9 demande par enquête), dont la moitié par des étudiant·es. En cumul, le site de Progedo indique à ce jour 26 740 demandes pour 1 739 enquêtes, soit environ 15 demandes par enquête en moyenne.

➔ Des **usages principalement pédagogiques**

Conclusion : à quelles conditions le jeu en vaut-il la chandelle ?

- Identifier les **personnes ressources** susceptibles d'accompagner à une démarche d'ouverture des données
- **Former toutes les équipes** à ces questions dès le début, en formation initiale et continue, pour limiter les coûts d'entrée
- **Allouer un budget et du temps** de travail dédié à ces questions en formalisant ces enjeux dans les projets de recherche
- **Etablir un protocole d'anonymisation en début de projet**, en même temps que les guides d'entretien, en choisissant les données que l'on veut conserver
- réaliser la **pseudo/anonymisation au maximum en même temps que la retranscription** pour éviter de double ou triple relectures, quitte à signaler les passages à couper ou à résumer pour la diffusion
- **Valoriser les compétences** liées au travail sur les données dans les CV scientifiques
- **Faire connaître les enquêtes** et les organismes déposant pour favoriser les réusages

➔ bref, disposer des ressources suffisantes, dans un contexte de destruction de la recherche publique…

Bibliographie (1/2)

Beauchemin C., Brilhault G., Morisset A., Simon P., Galonnier J., Le Courant S. & Noûs C. (2019), « Le travail des données. Entretien autour du service des enquêtes de l'INED », *Tracés. Revue de Sciences humaines*, nº 19, p. 163-181, DOI:10.4000/traces.10918.
Becker H. (2004), *Écrire les sciences sociales*, Paris, Economica.
Bendjaballah S. & Garcia G. (2023), « Les sciences sociales à l'épreuve de l'ouverture des données de la recherche », *Terrains & travaux*, vol. 43, nº 2, p. 211-216, DOI:10.3917/tt.043.0211.
Bendjaballah S., Garcia G., Cadorel S., Groshens E., Fromont E. & Juillard E. (2017), « Valoriser les données d'enquêtes qualitatives en sciences sociales : le cas français de la banque d'enquête beQuali », *Documentation et bibliothèques*, vol. 63, nº 4, p. 73-85, DOI:10.7202/1042306ar.
Bendjaballah S., Garcia G. & Sauger N. (2023), « Protéger les enquêtes, mais à quelles conditions ? Anonymiser des données d'enquêtes en sociologie et en science politique », *Terrains & travaux*, vol. 43, nº 2, p. 257-279, DOI:10.3917/tt.043.0257.
Bidart C., Bonneville A. & Garcia G. (2025), « Ouvrir les coulisses d'une recherche longitudinale : le Panel de Caen, réseaux et parcours de vie », *L'Année sociologique*, vol. 75, nº 1, p. 253-286, DOI:10.3917/anso.251.0253.
Bizeul D. (2021), « Faut-il tout dévoiler d'une enquête au Front national ? Réflexions sur le partage des données et le devoir éthique en sociologie », *Bulletin of Sociological Methodology/Bulletin de Méthodologie Sociologique*, vol. 150, nº 1, p. 70-105, DOI:10.1177/0759106320960887.
Bizeul D. (2026), « What Fieldwork Accounts Cannot Reveal: A Personal History of Practicing Sociology », *Bulletin of Sociological Methodology/Bulletin de Méthodologie Sociologique*, DOI:10.1177/07591063251400745.
Blien U., Muller W. & Wirth H. (1993), « L'anonymat des données individuelles : études des risques d'identification », *Sociétés contemporaines*, nºs 14-15, p. 23-42, DOI:10.3406/socco.1993.1125.
Bouchet C. (2024), « Comment j'ai déposé les données de ma recherche (sans savoir ce qui m'attendait) », *Genèses. Sciences sociales et histoire*, nº 133, p. 113-128, DOI:10.3917/gen.133.0113.
Boué M., Mazuy M., Mullner P. & Wicky L. (2024), « Le travail émotionnel dans les recherches sur les violences de genre. Regards croisés sur un impensé au sein du monde académique », *Socio-logos. Revue de l'association française de sociologie*, nº 20, DOI:10.4000/socio-logos.6778.
Boulet E. (2020), *Espaces et temps de la « production d'enfants » : sociologie des grossesses ordinaires* (Thèse de doctorat, Université Lyon 2 Lumière), http://www.theses.fr/s174403.
Brunel V., Danciu A. & Lamrini N. (2023), « Mettre à disposition des données quanti dans le respect du cadre juridique relatif à la vie privée. Pratiques d'anonymisation en SHS », *Statistique et société*, vol. 11, nº 3, DOI:10.4000/statsoc.1272.
Cadorel S., Garcia G., Groshens É., Juillard É., Vandenbunder J., Le Courant S., … Noûs C. (2019), « Archiver, documenter, enquêter sur l'enquête qualitative. Le travail de l'ombre de beQuali », *Tracés. Revue de Sciences humaines*, nº 19, p. 183-198, DOI:10.4000/traces.10968.
Caratini S. (2012), *Les non-dits de l'anthropologie suivi de Dialogue avec Maurice Godelier*, Vincennes, T. Marchaisse « Les non-dits ».
Cavallo D. & Noûs C. (2019), « Données à penser. Enjeux pratiques et éthiques autour des données dans le montage de projets de recherche européens », *Tracés. Revue de Sciences humaines*, nº 19, p. 101-113, DOI:10.4000/traces.10793.
Chateigner F. (2008), *Une société littéraire. Sociologie d'un atelier d'écriture*, Bellecombe-en-Bauges, Éditions du Croquant.
Coulmont B. (2017), « Le petit peuple des sociologues. Anonymes et pseudonymes dans la sociologie française », *Genèses*, nº 107, p. 153-175, DOI:10.3917/gen.107.0153.
Courmont A. (2017), « De la « donnée » à la « donnée ouverte » : les épreuves de l'ouverture des données », *Statistique et société*, vol. 5, nº 3, p. 19-23, DOI:10.3406/staso.2017.1045.
Dagiral É. & Peerbaye A. (2012), « Les mains dans les bases de données:Connaître et faire reconnaître le travail invisible », *Revue d'anthropologie des connaissances*, vol. 61, nº 1, p. 191-216, DOI:10.3917/rac.015.0229.
Danciu A. & Gallis Q. (2021, mai 17), « Utilisation secondaire des données diffusées par le CDSP : exemples », *Colloque « Organiser, documenter, déposer et réutiliser des données en histoire »*, *Axe « Archives et histoire numérique »*, Paris, Centre d'histoire de Sciences Po, DOI:10.5281/ZENODO.4722869.

Bibliographie (2/2)

Denis J. (2018), *Le travail invisible des données : Éléments pour une sociologie des infrastructures scripturalesLe travail invisible des données : Éléments pour une sociologie des infrastructures scripturales*, Paris, Presses des Mines « Sciences sociales », https://books.openedition.org/pressesmines/3934.
Duchesne S. & Noûs C. (2019), « Apories de la mise en banque : retour d'expérience sur la réutilisation d'enquêtes qualitatives », *Tracés. Revue de Sciences humaines*, nº 19, p. 89-100, DOI:10.4000/traces.10738.
Duwez E. & Mercklé P. (dir.) (2021), *Un panel français. L'étude longitudinale par Internet pour les sciences sociales (ELIPSS)*, Paris, Ined Éditions « Grandes enquêtes », DOI:10.4000/books.ined.16275.
Duwez E. & Mercklé P. (2024), « Construire un dispositif d'enquêtes longitudinales pour la recherche en sciences sociales : le panel ELIPSS », *L'Année sociologique*, vol. 74, nº 1, p. 251-273, DOI:10.3917/anso.241.0251.
El Miri M. & Masson P. (2010), « Une charte de déontologie est-elle utile ? », *in* Laurens S. & Neyrat F. (dir.), *Enquêter : de quel droit ? Menaces sur l'enquête en sciences sociales*, Bellecombe-en-Bauges, Éditions du Croquant, p. 267-290.
Katz J. (2022), « Une armure pour les ethnographes », *Genèses*, nº 129, p. 30-46, DOI:10.3917/gen.129.0030.
Khan S. R. (2022), « L'assignation à comparaître et la saisie des données ethnographiques », *Genèses*, nº 129, p. 14-29, DOI:10.3917/gen.129.0014.
Laurens S. & Neyrat F. (2010), *Enquêter : de quel droit ? Menaces sur l'enquête en sciences sociales*, Bellecombe-en-Bauges, Éditions du Croquant.
Lazar J. (2001), *Les secrets de famille de l'université*, Paris, les Empêcheurs de penser en rond.
Lebaron F. (2021), « Quels enjeux socio-économiques pour les données des sciences sociales ? », *Revue internationale de droit économique*, nº 3, p. 9-18, DOI:10.3917/ride.353.0009.
Lemarchant C. (2018), « Pinar Selek, une vie d'exil », *Travail, genre et sociétés*, vol. n° 40, nº 2, p. 5-22, DOI:10.3917/tgs.040.0005.
Lutard-Tavard C. (2014), « Être à la barre, être accusé(e) », *Socio*, nº 3, p. 63-78, DOI:10.4000/socio.578.
Marchal R., Laurens S. & Siméant-Germanos J. (2022), « Le chercheur suspect et espion par association : entretien avec Roland Marchal », *Genèses*, vol. 129, nº 4, p. 138-152, DOI:10.3917/gen.129.0138.
Mohammed M. & Noûs C. (2019), « Vers une neutralisation juridique et bureaucratique des recherches sur des sujets sensibles ? », *Tracés. Revue de Sciences humaines*, nº 19, p. 115-128, DOI:10.4000/traces.10843.
Nicaise S. & Sorignet P.-E. (2026), « La protection des données et le métier de sociologue », *Regards sociologiques*, nº 66, p. 57-74.
Perrin R. (2023), « L'ethnographie comme travail émotionnel : une enquête de terrain sur l'avortement », *Genèses*, nº 132, p. 97-115, DOI:10.3917/gen.132.0097.
Perrin R. (2025), *Le choix d'avorter: sur le contrôle médical du corps des femmes*, Marseille, Agone.
Perry A. & Netscher S. (2022), « Measuring the time spent on data curation », *Journal of Documentation*, vol. 78, nº 7, p. 282-304, DOI:10.1108/JD-08-2021-0167.
Pirus C., Bois C., Dufourg M.-N., Lanoë J.-L., Vandentorren S. & Leridon H. (2010), « La construction d'une cohorte : l'expérience du projet français Elfe », *Population*, vol. 65, nº 4, p. 637-670, https://shs.cairn.info/revue-population-2010-4-page-637.
Rabier C. & Noûs C. (2019), « Données de la recherche hier et aujourd'hui : pour une histoire politique du travail en sciences humaines et sociales », *Tracés. Revue de Sciences humaines*, nº 19, p. 51-66, DOI:10.4000/traces.10643.
Silberman R. (2024), « Partage des données et protection de la confidentialité : quels nouveaux enjeux pour les sciences sociales ? », *L'Année sociologique*, vol. 74, nº 2, p. 529-559, DOI:10.3917/anso.242.0529.
Siméant-Germanos J. (2022), « Qui protéger, consentir à quoi, enquêter comment ? Les sciences sociales face à la bureaucratisation de la vertu scientifique », *Genèses*, nº 129, p. 66-87, DOI:10.3917/gen.129.0066.
Stérin A.-L. & Noûs C. (2019), « Ouverture des données de la recherche : les mutations juridiques récentes », *Tracés. Revue de Sciences humaines*, nº 19, p. 37-50, DOI:10.4000/traces.10603.
Tanghe H. & Gibert P.-O. (2017), « L'enjeu de l'anonymisation à l'heure du big data », *Revue française des affaires sociales*, nº 4, p. 79-93, DOI:10.3917/rfas.174.0079.
Torreiro J. J. & Sommier I. (2010), « Écriture sociologique et labellisation politique : réflexions autour d'un procès en diffamation », *in* Laurens S. & Neyrat F. (dir.), *Enquêter : de quel droit ? Menaces sur l'enquête en sciences sociales*, Bellecombe-en-Bauges, Éditions du Croquant, p. 39-54.
Tréguer F. & Noûs C. (2019), « Les chercheurs face à la surveillance d'État : état des lieux et contre-mesures », *Tracés. Revue de Sciences humaines*, nº 19, p. 129-144, DOI:10.4000/traces.11038.
Waquet F. (2022), *Dans les coulisses de la science: techniciens, petites mains et autres travailleurs invisibles*, Paris, CNRS éditions.
Zolesio E. (2011), « Anonymiser les enquêtés », *http://www.revue-interrogations.org*, nº 12, https://www.revue-interrogations.org/anonymiser-les-enquetes.

Merci de votre attention !

Zoom sur le protocole d'anonymisation

L’exemple des questions ouvertes

Identifiant	Source	Suppressions
4957	Départ de notre neveu que l'on a hébergé 5 ans	5
25134	notre fille est partie étudier à Limoge en septembre 2022 et ne rentre que les vacances	Limoges |septembre 2022
25124	Je vis toujours seule avec mes deux enfants mais j’ai déménagé, avec eux. Et, récemment j’ai rencontré quelqu’un.	deux
9864	Mon père déjà fragile est mort du covid en mars 2022	mars 2022
6244	Ma fille qui a vécu le confinement avec nous puis est partie est revenue depuis quelques semaines (pour des raisons de travail)	
14902	Nous nous sommes mariés après 5 ans de vie commune	5 ans
10994	En 2021-2022, j'ai effectué une année de césure. Début 2022, j'habitais chez mes parents près de Nantes, puis j'ai pris une colocation à Nantes	En 2021-2022| 2022|Nantes|Nante|3 mois a| 2022| Paris | fin juillet 2023| 1 an.
1685	Séparation puis nouveau conjoint	
7499	Séparation cause projets bloqués puis reprise de relation et réalisation d un achat immobilier ensemble	
23276	Ma conjointe est en suis médical suite à ce confinement, il est question du syndrome de Peter Pan.... Nous nous sommes séparés depuis....	de Peter Pan
19670	une fille qui a quitté le foyer pour faire ses études	
3036	Mon fils a pris un logement avec sa copine en décembre 2022	décembre 2022

2.3 En pratique… Les lieux

- Anonymiser des villes

D'accord et du coup à quelle fréquence vous vous voyez ?

On va dire quelques fois par semaine, non peut-être pas… on va dire plusieurs fois par mois, on va dire plusieurs par mois, je ne saurais pas donner un nombre exact parce que le problème c'est qu'elle, elle habite à [grande ville de France, à plus de 500km]. Bon j'ai des impératifs universitaires à [grande ville de France], du coup ça me donne l'occasion de la voir aussi beaucoup plus régulièrement et là ce que j'envisage, c'est de prendre [solution de transport] pour faire des allers-retours beaucoup plus souvent et créer du contact social de manière générale.

- Anonymiser d'autres zones géographiques

Parce que j'ai un de mes fils qui est hippie, enfin il fait parti de gens qui vivent en van, les vanlife, et il se balade partout en Europe. Et quand ils ont su que le confinement arrivait, ils ont décidé de se regrouper dans [une zone géographique montagneuse de France] avec d'autres dans un grand squat avec tout ceux qui ont été sorti des stations

- Garder la **cohérence interne**

Ben de certains amis que je fréquente plus parce que quand je suis partie de [la moyenne ville de France, lieu de résidence passé mentionnée plus tôt] je les ai bien plantés [là-bas]. Et comme j'ai changé le numéro de téléphone… Alors ils essayent de

Le mercredi, laisse-moi tomber. J'ai dit à ma copine, « avant ils vendaient des vêtements pour les enfants ou ils vendaient des vêtements pour nous », pour… Maintenant, qui y va ? Il n'y a que des djellabas. Même les enfants, il y a plus de petits trucs mignons, vous savez, pour les petites filles. C'est tout des trucs qui sont comme ça, même pour les trucs de l'été avec des trucs jusqu'à là. Ils vendent des voiles pour les enfants ! J'ai dit à ma copine, « ils sont pas sérieux là ». J'ai dit « c'est bon, je retourne à mon marché de [un village de France à quelques kilomètres, lieu de résidence actuel] ».

Donc, [cet autre marché], c'est mieux.

2.3 En pratique… Nationalités et lieux de vacances

- Les lieux de vacances : on garde la zone géographique globale (par continents), avec les détails qui peuvent être pertinents (ex : île)

On a fait le passe sanitaire, on est parti en [Pays d'Europe de l'Est], donc on a traversé [Pays d'Europe de l'Est], la [Pays d'Europe extra communautaire], on est descendu par la route, la [Pays d'Europe extra communautaire], on est passé en [Pays d'Europe de l'Est], on est passé en [Pays d'Europe centrale], on est passé en [Pays d'Europe centrale], on est est passé en [Pays du Sud de l'Europe] pour rentrer. Personne ne nous a jamais demandé le moindre pass sanitaire.

OU

On a fait le passe sanitaire, on est parti en [énumération de 8 pays d'Europe]. Personne ne nous a jamais demandé le moindre pass sanitaire. → ce que nous avons choisi

2.3 En pratique…
Les entreprises, les professions

- Les entreprises

Donc lui, il travaillait la journée, c'était plus facile. Et Frédérique [1090_R_1] ne travaille pas ?

Si, elle est directrice d'un [magasin qui fait partie d'une chaîne] mais le problème c'est qu'elle avait posé ses vacances, et elle les a gardées. Et comme elle venait de prendre la direction de ce [magasin] à [ville moyenne de France mentionnée plus tôt], elle venait

Alors, j'ai ma fille. Ma fille aînée qui a 30 ans. Elle est ingénieure et elle bosse chez [une grande entreprise qui crée et commercialise des produits électroniques]. Mon fils, il a 27 ans. Il est en thèse. Vous êtes en thèse, vous ?

- Les études

Alors il y avait trois ami.e.s qui sont dans la même licence que moi et ensuite 2 amies qui elles, il y en a une qui est en […] droit et histoire de l'art et une autre qui en […] en droit.

- Les **professions**

Et vous travailliez sur quoi en tant qu'océanographe ?

Ah, ben, en 42 ans, j'ai fait pas mal de choses. J'ai travaillé sur les... J'ai fait ma thèse sur le récif corallien de Tuléar. Ensuite, j'ai travaillé un peu partout. Et sur... J'ai fait la pêche aux anchois dans le golfe de Gascogne. J'ai fait... J'ai... J'ai fini par le... Je travaillais sur les poissons. Ensuite, sur les micro-algues. Ensuite, j'ai fait... J'ai travaillé sur l'acoustique sous-marine pour améliorer les sondeurs et sonars.

anonymisation : hyperonomies, coupes…

Et vous travailliez sur quoi en tant que [métier intellectuel en lien avec l'univers marin] ?

Ah, ben, en 42 ans, j'ai fait pas mal de choses. J'ai travaillé sur les... J'ai fait [une] thèse [...]. Ensuite, j'ai travaillé un peu partout. [...] J'ai fait... J'ai... J'ai fini par le... Je travaillais sur les poissons. Ensuite, sur [autre chose]. Ensuite, j'ai fait... J'ai travaillé sur l'acoustique sous-marine [...].

2.3 En pratique… Les personnes mentionnées en entretiens

- Pseudonymisation à partir de l'outil de **Baptiste Coulmont** + les **statistiques** sur la fréquence des prénoms en fonction de l'année de naissance

> Des fois une fois par mois, tous les deux mois, ça dépendait ! Régulièrement j'allais passer un weekend à [ville moyenne de France mentionnée plus tôt]. C'a a toujours été mes enfants que je vois le plus Hugo et Frédérique [1090_R_1]. Parce que Lina [1090_R_2], petite, elle était très malade et comme je suis infirmière, c'est moi qui allais faire les nuits là-bas parce qu'ils étaient épuisés.

1090_R_2	Léana	Lina
1090_D_2	Françoise	Claudie
1090_R_3	Dolores	Cynthia
1090_D_3	Carla	Clara
1090_R_4	Sabine	Bérangère
1090_R_5	Jean Yves	Maurice
1112_R_1	Adèle	Garance

l

des alters

- D'autres techniques astucieuses (Wikipédia)

2.3 En pratique… Etat de santé

- Les problèmes de santé : laisser les problèmes non identifiants, couper ou hyperonymiser quand c'est possible.

Bah, quand je me suis prise de passion pour [le pays d'Asie du sud précédemment cité], j'ai appris à faire des massages [typiques], donc j'ai… quand j'ai quitté la boîte pour laquelle j'ai bossé, je me suis mise en rupture conventionnelle, j'ai monté un truc de massage qui marchait plutôt pas mal, et puis je suis tombée malade. Et puis j'ai eu un cancer […], et puis un deuxième cancer […]. Donc c'était il y a… dix ans, ça ? Ouais, c'est ça. C'était il y a dix ans.

En fait, après, quand j'ai eu le cancer, j'ai été pas mal malade. Parce que j'ai fait après une [maladie grave qui touche le système respiratoire].